

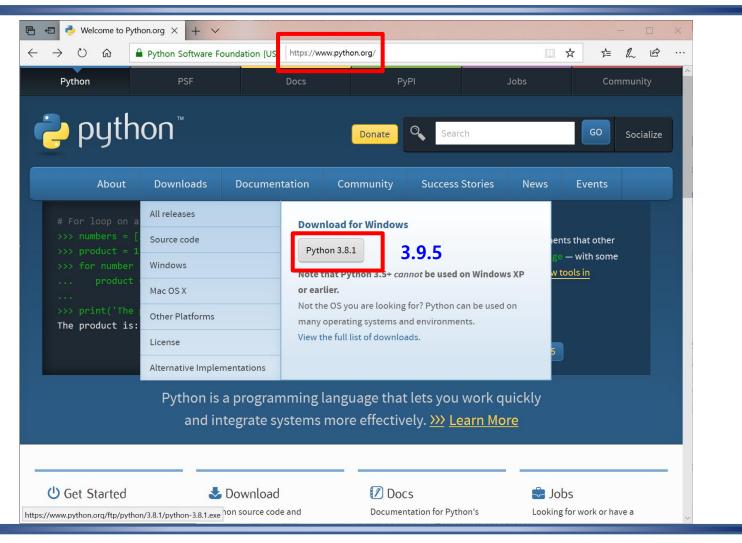


Prerequisite for ML-based NLP

Practical Exercise



Python 설치



Python 설치



Python 설치 확인

```
Microsoft Windows [Version 10.0.18363.657]
(c) 2019 Microsoft Corporation. All rights reserved.

C:\Users\Partial \frac{1}{2} \rightarrow \rightarrow
```

PIP (Python Package Index)

• PIP: 파이썬으로 작성된 패키지 소프트웨어를 관리하는 패키지 관리 시스템

Numpy, Scipy, Matplot 설치

- Numpy: 행렬이나 다차원 배열을 쉽게 처리 할 수 있도록 지원하는 라이브러리
- Scipy: 과학 컴퓨팅과 기술 컴퓨팅에 사용되는 라이브러리
- Matplot: 유사한 그래프 표시를 가능케 하는 라이브러리

```
₫ 명령 프롬프트
<u>(c) 2019 Microsoft Corporation. All rights reserved.</u>
C:₩Users₩김<mark>학수>python -m pip install numpy scipy matplotlib</mark>
Collecting humpy
  Downloading https://files.pythonhosted.org/packages/0e/c3/be53614c4e3490778050e1df48fd463837297d5
dd402dae3b500f2050eba/numpy-1.18.1-cp38-cp38-win32.whl (10.8MB)
                                             -10.8MB 1.1MB/s
Collecting scipy
  Downloading https://files.pythonhosted.org/packages/db/9e/465a416eb04114e3722b17b0f4fa5235bab8a76
961de51db0e5850183fb1/scipy-1.4.1-cp38-cp38-win32.whl (27.9MB)
                                             27.9MB 3.3MB/s
Collecting matplotlib
Downloading https://files.pythonhosted.org/packages/86/e4/1ef1cb7f2c52345a7e3c8efd3de7ec943818c0011c839b4880c0ba0bb7b1/matplotlib-3.1.3-cp38-cp38-win32.whl (8.9MB)
                                             8.9MB 6.8MB/s
Collecting kiwisolver>=1.0.1 (from matplotlib)
Downloading https://files.pythonhosted.org/packages/b9/b1/118f3d5dee660bbe4548f06dcd0e1a10e454583
26c3d0efad7dbbf28be24/kiwisolver-1.1.0-cp38-none-win32.whl (43kB)
```



Numpy, Scipy, Matplot 설치

```
C:WUsers#김학수>python
Python 3.8.1 (tags/v3.8.1:1b293b6, Dec 18 2019, 22:39:24) [MSC v.1916 32 bit (Intel)] on win32
Type "beln" "convright" "credits" or "license" for more information
>>> import numpy
>>> import scipy
>>> import matplotlib
```

Jupyter Notebook 설치

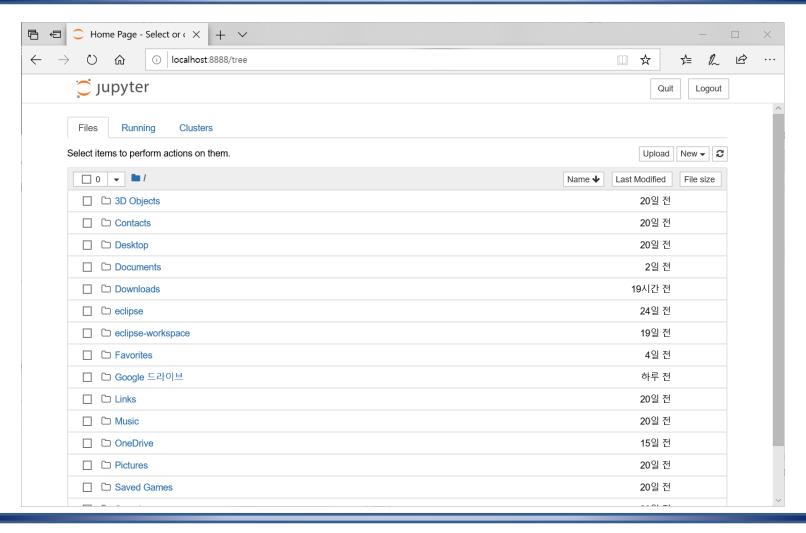
• Jupyter Notebook: 웹 브라우저에서 파이썬 코드를 작성하고 실행 해 볼 수 있는 개발도구

```
ፙ 명령 프롬프트
                                                                                                  \times
C:₩Users₩김학수>python -m pip install jupyter
Collecting jupyter
 Downloading jupyter-1.0.0-py2.py3-none-any.whl (2.7 kB)
Collecting nbconvert
  Downloading nbconvert-5.6.1-py2.py3-none-any.whl (455 kB)
                                        455 kB 234 kB/s
Collecting ipywidgets
  Downloading ipywidgets-7.5.1-py2.py3-none-any.whl (121 kB)
                                       -121 kB 6.4 MB/s
Collecting atconsole
  Downloading qtconsole-4.6.0-py2.py3-none-any.whl (121 kB)
                                       121 kB 6.8 MB/s
Collecting ipykernel
  Downloading ipykernel-5.1.4-py3-none-any.whl (116 kB)
                                       116 kB 6.4 MB/s
Collecting jupyter-console
  Downloading jupyter console-6.1.0-py2.py3-none-any.whl (21 kB)
```

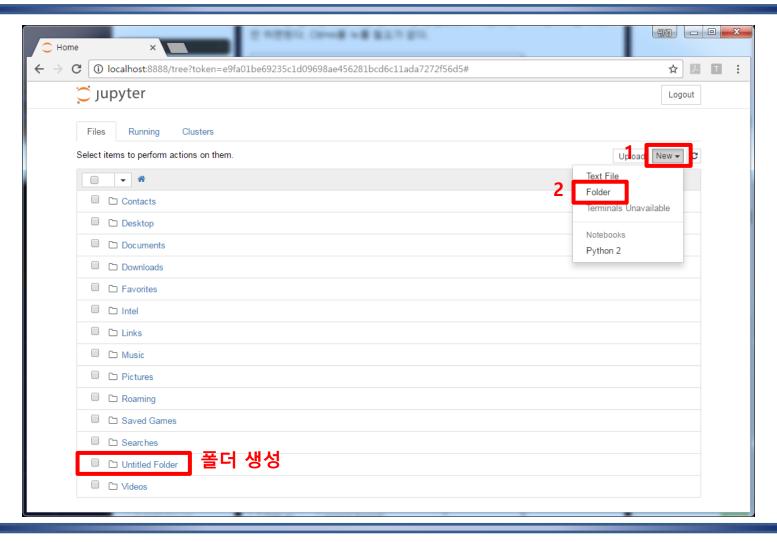
Jupyter 실행

```
X
 ■ 명령 프롬프트 - jupyter notebook
                                                                                      ː刪sers#김학스
 :₩Users₩김학┵>jupyter notebook
[| 10:24:19.84<del>0 NotebookApp] Writing note</del>book server cookie secret to C:#Users#김학수#A
ppData#Roaming#jupyter#runtime#notebook_cookie_secret
[W 10:24:20.300 NotebookApp] Terminals not available (error was No module named 'winpty
.cywinpty')
   -10:24:20.300 NotebookApp] Serving notebooks from local directory: C:₩Users₩김학수
  10:24:20.300 NotebookApp] The Jupyter Notebook is running at:
   10:24:20.300 NotebookApp1 http://localhost:8888/?token=a3bf7025eebf7610c5973563a1649
4be8c39ce8082947215
                                or http://127.0.0.1:8888/?token=a3bf7025eebf7610c5973563a
   10:24:20.300 NotebookApp]
16494be8c39ce8082947215
  10:24:20.300 NotebookAppl Use Control-C to stop this server and shut down all kernel
  (twice to skip confirmation).
[C 10:24:20.331 NotebookApp]
    To access the notebook, open this file in a browser:
        file:///C:/Users/%EA%B9%80%ED%95%99%EC%88%98/AppData/Roaming/jupyter/runtime/nb
server-14056-open.html
       copy and paste one of these Units:
http://localhost:8888/?token=a3bf7025eebf7610c5973563a16494be8c39ce8082947215
     UI IILLD-//127.U.U.1-0000/?LUKEII-aDDI70ZDEEDI7010CDB7DDDBAT0494DEOCDBCEOVOZB47Z1D
  10:25:28.675 NotebookApp] 302 GET /?token=a3bf7025eebf7610c5973563a16494be8c39ce8082
947215 (::1) 0.00ms
```

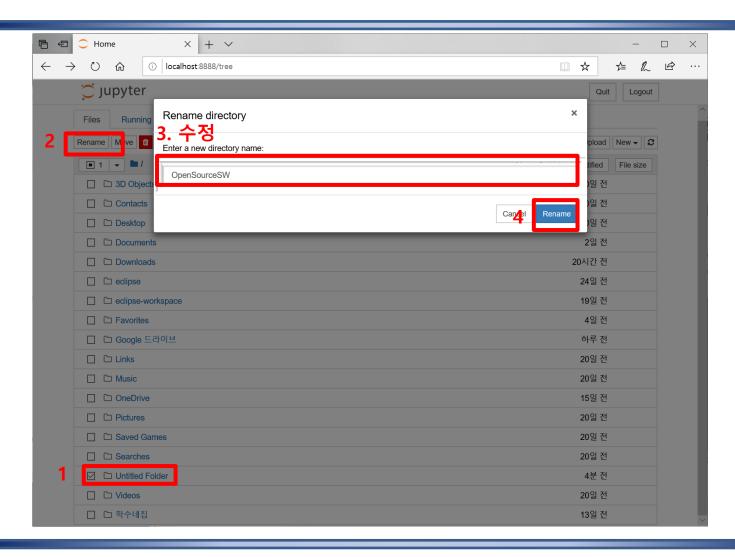
Jupyter 실행 화면



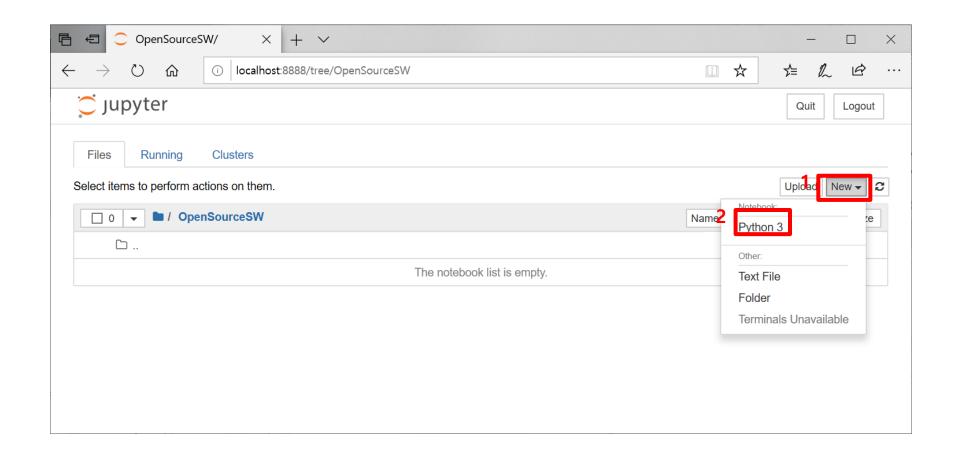
Jupyter 폴더 생성



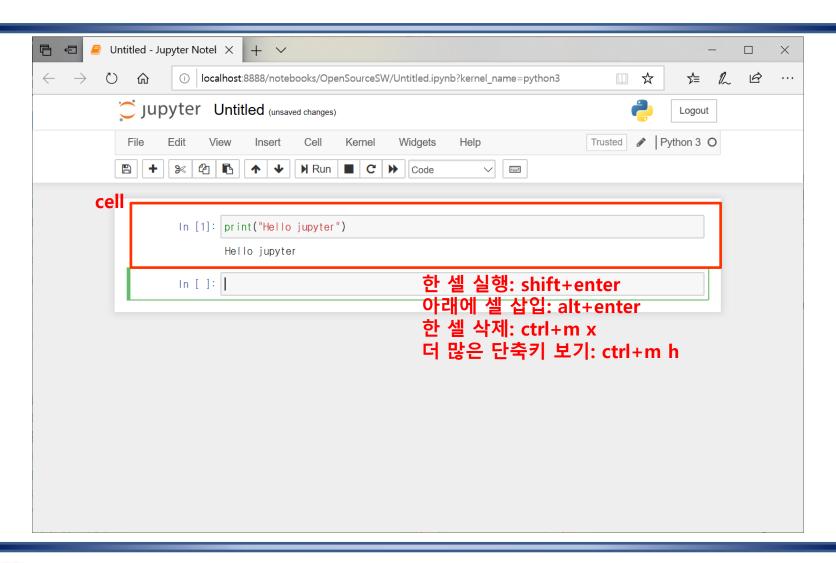
Jupyter 폴더 이름 수정



Jupyter로 python 실행



Jupyter로 python 코딩하기



Scikit-learn

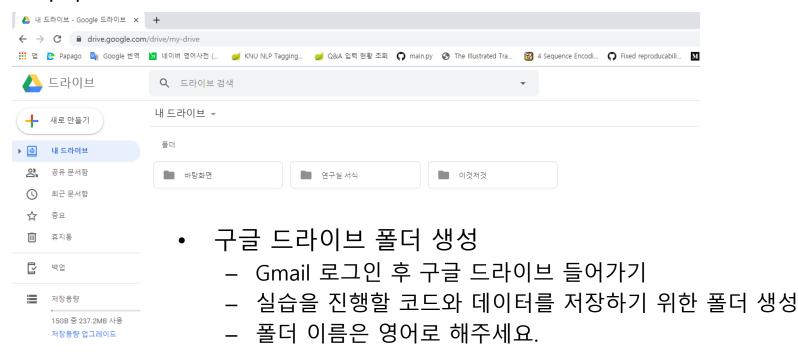
 scikit-learn: 파이썬으로 작성된 데이터 분석을 위한 범용 오픈 소스 라이브러리

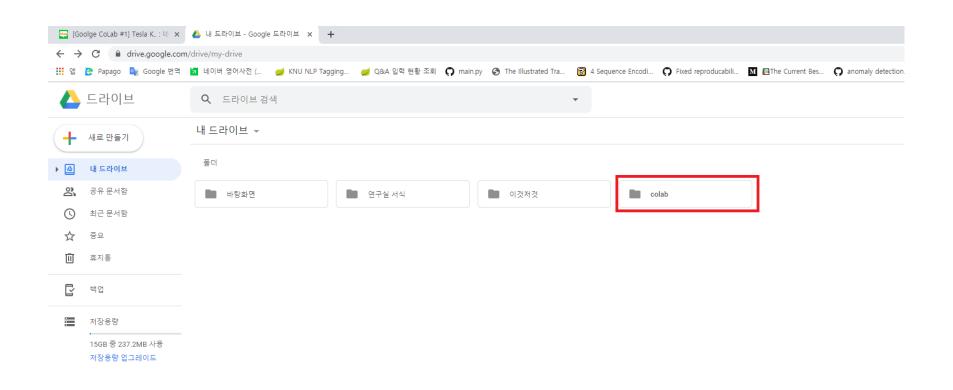
```
₫ 명령 프롬프트
                                                                                                       \times
Microsoft Windows [Version 10.0.18363.657]
(c) 2019 Microsoft Corporation. All rights reserved.
C:₩Users₩김학♣>python -m pip install scikit-learn
Collecting sci<del>kit learn</del>
  Downloading scikit learn-0.22.1-cp38-cp38-win32.whl (5.6 MB)
                                              5.6 MB 6.8 MB/s
Requirement already satisfied: numpy>=1.11.0 in c:\users\langla 라수\uppdata\local\programs\py
thon\python38-32\lib\site-packages (from scikit-learn) (1.18.1)
Requirement already satisfied: scipy>=0.17.0 in c:\users\u2 학수\appdata\local\programs\py
thon\python38-32\lib\site-packages (from scikit-learn) (1.4.1)
Collecting joblib>=0.11
  Downloading joblib-0.14.1-py2.py3-none-any.whl (294 kB)
                                              294 kB 89 kB/s
Installing collected packages: joblib, scikit-learn
Successfully installed joblib-0.14.1 scikit-learn-0.22.1
C:₩Users₩김학수>python
Python 3.8.1 (tags/v3.8.1:1b293b6, Dec 18 2019, 22:39:24) [MSC v.1916 32 bit (Intel)] on
<u>Type "beln" "convright" "credits" or "license" for more information.</u>
>>> import sklearn
                                                설치 확인
```

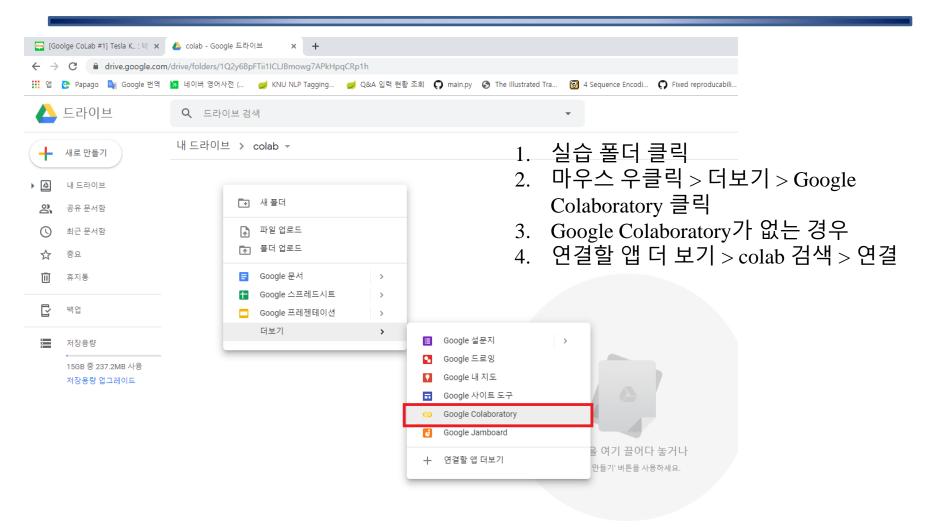


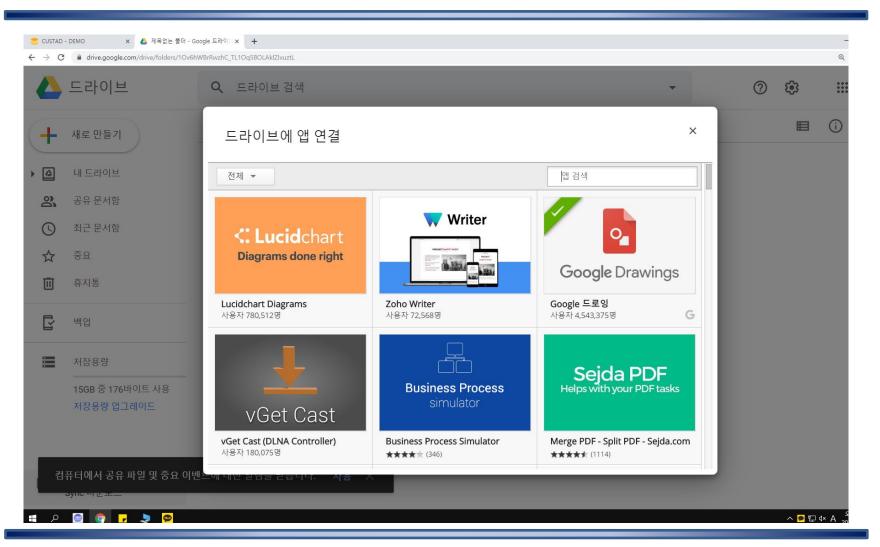
Google Colab

• Google Colab: AI 개발자들을 위해 구글에서 제공하는 무료 클라우 드 서비스

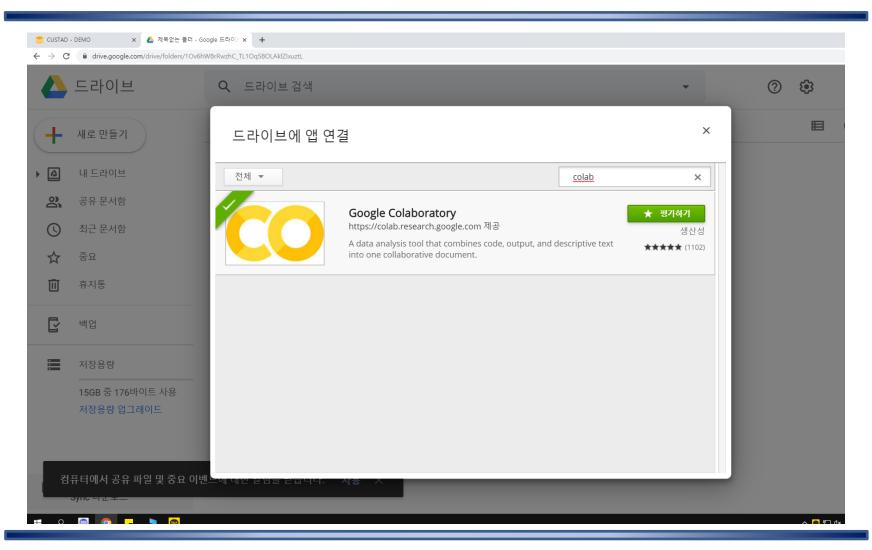


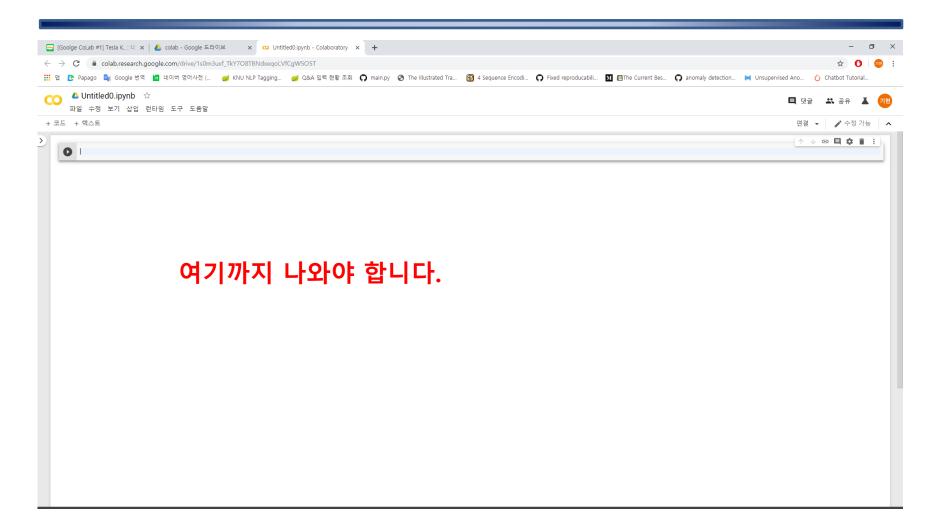












구글 드라이브 연동

- 개인의 구글 드라이브와 코랩 클라우드를 연동
 - 코랩 클라우드에 바로 파일을 업로드하면 일정 시간 후에 해당 파일이 삭제됨
 - 따라서 구글 드라이브에 파일을 업로드 하고 이를 코 랩 클라우드와 연동하여 사용

구글 드라이브 연동

```
from google.colab import drive
drive.mount('/gdrive', force_remount=True)
```

위의 코드 입력 후 shift+enter 을 눌러 코드 실행

```
from google.colab import drive drive.mount('/gdrive', force_remount=True)

Go to this URL in a browser: <a href="https://accounts.google.com/o/oauth2/auth?client_id=947318989803">https://accounts.google.com/o/oauth2/auth?client_id=947318989803</a>
Enter your authorization code:
```

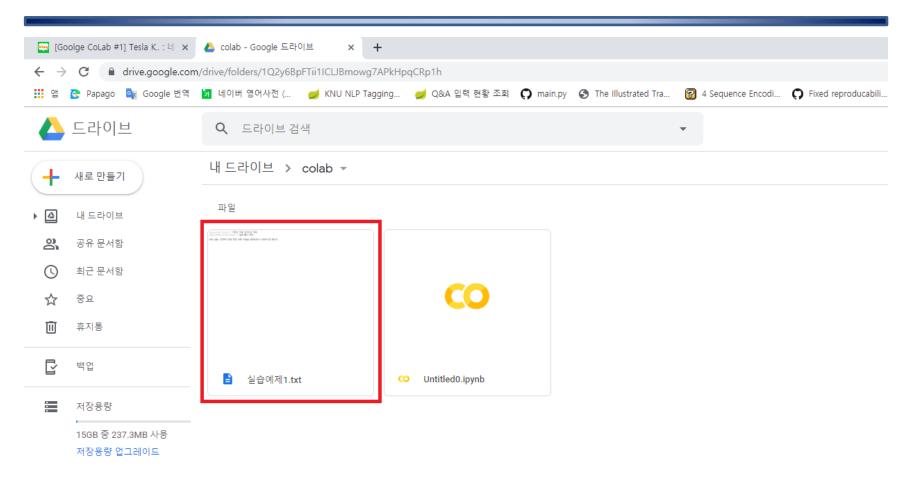
링크 선택 > 자신의 계정 선택 > 엑세스 허용 > 인증 코드 복사하여 입력



구글 드라이브 연동

"Mounted at /gdrive" 라는 메시지가 뜨면 연동 완료

파일 업로드



실습 폴더에 "실습예제1.txt" 파일 업로드

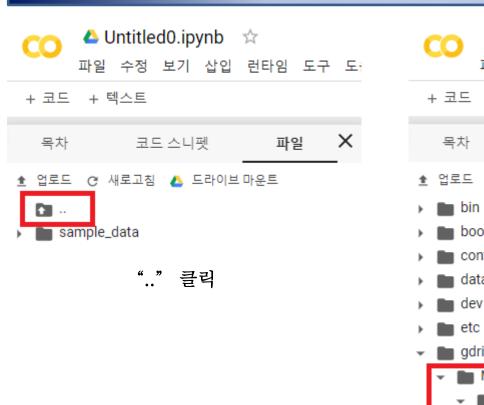


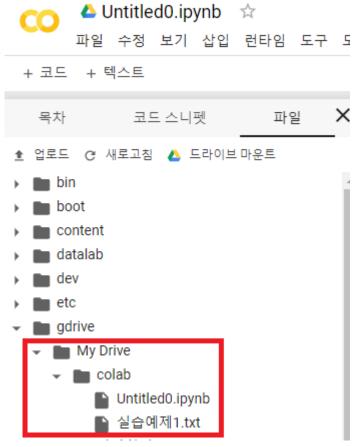
파일 업로드

plod	Goolge	e CoLab #1] Tesl	а К : Ц ×	📤 colab -	Google 드라이!	± ×	co Untitle	ed0.ipynb - Colal	boratory ×	+		
\leftarrow	← → C a colab.research.google.com/drive/1s0m3uxf_TkY7O8TBNdxeqoLVfCgW5O5T#scrollTo=IkTfL9-sEleT											
앝	<u>C</u>	Papago 🚉 (Google 번역	과 데이버 8	령어사전 (🥖 KNU NLP	Tagging	Ø Q&A 입력	현황 조회	nain.py	The Illustrated Tr	a 🔞
CC	•	Ů Untitled0. 1일 수정 보기			도움말							
+ 코	<u> </u>	+ 텍스트										
>	[]	from google drive.mount			unt=True)							
	₽	Mounted at /	gdrive									
	[]											

왼쪽 상단 화살표 클릭

파일 업로드





실습예제1.txt이 보이면 업로드 완료

업로드 한 파일 출력

[9] from google.colab import drive drive.mount('/gdrive', force_remount=True)

Description

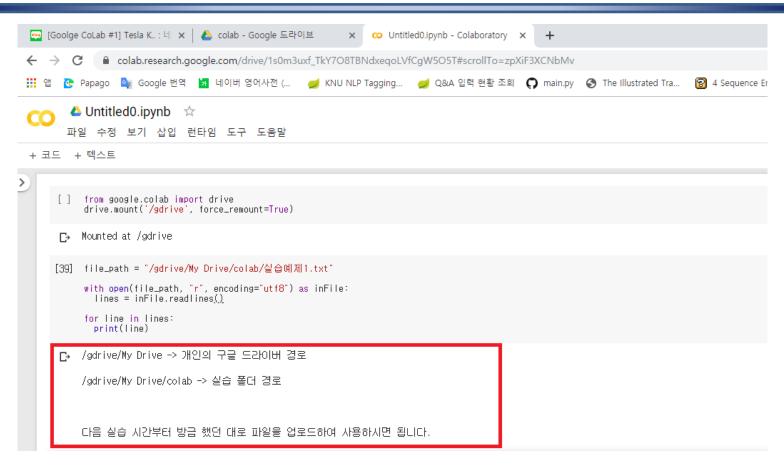
Mounted at /gdrive

file_path = "/gdrive/My Drive/colab/실습예제1.txt"

with open(file_path, "r", encoding="utf8") as inFile:
 lines = inFile.readlines()
 for line in lines:
 print(line)

위의 코드 입력 후 코드 실행

업로드한 파일 출력



위 내용이 출력되면 성공!







Deep Neural Network

컴퓨터공학부 / 인공지능학과(대학원)

김학수



XOR by PyTorch

```
# GPU 사용 가능 여부 확인
                                                                                                        H(X) = \frac{1}{1 + e^{-W^T X}}
if torch.cuda.is_available():
  device = 'cuda'
else:
  device = 'cpu'
                                                                                                                           W_2 = \begin{bmatrix} \dots \\ \dots \end{bmatrix}
                                                                                                          b_2 = [ ... ]
input_features, labels = load_dataset("/gdrive/My Drive/colab/ann/xor/train.txt",device)
# NN 모델 만들기
                                                                                                                              W_1 = \begin{bmatrix} \dots & \dots \\ \dots & \dots \end{bmatrix}
model = nn.Sequential(
           nn.Linear(2, 2, bias=True), nn.Sigmoid(),
           nn.Linear(2, 1, bias=True), nn.Sigmoid()).to(device)
                                                                                                             x_1
# 이진분류 크로스엔트로피 비용 함수
loss_func = torch.nn.BCELoss().to(device)
# 옵티마이저 함수 (역전파 알고리즘을 수행할 함수)
optimizer = torch.optim.SGD(model.parameters(), Ir=1)
                                                                                   Cost(w)
                                                                                   = -\frac{1}{m} \sum_{x} y \log(H(x)) + (1-y) \log(1-H(x))
# 학습 모드 셋팅
model.train()
                                                                                  W := W - \alpha \frac{\partial}{\partial W} cost(W)
```

XOR by PyTorch

학습 실행 및 코스트 출력

```
# 모델 학습
for epoch in range(1001):

# 기물기 계산한 것들 초기화
optimizer.zero_grad()

# H(X) 계산: forward 연산
hypothesis = model(input_features)

# 비용 계산
cost = loss_func(hypothesis, labels)
# 역전파 수행
cost.backward()
optimizer.step()

# 100 메폭마다 비용 출력
if epoch % 100 == 0:
print(epoch, cost.item())
```

예측(0과 1로 변환) 및 정밀도 계산

```
# 평가 모드 셋팅 (학습 시에 적용했던 드랍 아웃 여부 등을 비적용)
model.eval()
# 역전파를 적용하지 않도록 context manager 설정
with torch.no_grad():
    hypothesis = model(input features)
    logits = (hypothesis > 0.5).float()
    predicts = tensor2list(logits)
    golds = tensor2list(labels)
    print("PRED=".predicts)
    print("GOLD=",golds)
    print("Accuracy : {0:f}".format(accuracy score(golds, predicts)))
0 0.6988072395324707
100 0.693162202835083
200 0.6930413246154785
300 0.692793071269989
400 0.6919294595718384
500 0.6865977048873901
600 0.6376820802688599
700 0.5430010557174683
800 0.3161814212799072
900 0.0973285436630249
1000 0.051614370197057724
PRED= [[0.0], [1.0], [1.0], [0.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]
Accuracy : 1,000000
```

Wide ANN

Hidden layer를 2*2에서 2*10으로 변경

```
# NN 모델 만들기
?
```

더 빨리 수렴함 (학습 속도는 느려짐)

Widening은 선의 개수를 늘리는 효과!

```
0 0.6988072395324707

100 0.693162202835083

200 0.6930413246154785

300 0.692793071269989

400 0.6919294595718384

500 0.6865977048873901

600 0.6376820802688599

700 0.5430010557174683

800 0.3161814212799072

900 0.0973285436630249

1000 0.051614370197057724

PRED= [[0.0], [1.0], [1.0], [0.0]]

GOLD= [[0.0], [1.0], [1.0], [0.0]]
```



```
100 0.6920320987701416
200 0.6887232065200806
300 0.6461161971092224
400 0.3004415035247803
500 0.09012892842292786
600 0.04456526041030884
700 0.028334952890872955
800 0.020417045801877975
900 0.01582087203860283
1000 0.01284930482506752
PRED= [[0.0], [1.0], [1.0], [0.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]
```

0 0.7083522081375122

Shallow ANN

Hidden layer를 없애고 Single-layer Perceptron으로 변경

```
# NN 모델 만들기
model = nn.Sequential(
nn.Linear(2, 1, bias=True), nn.Sigmoid()).to(device)
```

Non-linear Separable Problem

학습 속도는 빠르지만 10,000 epoch를 수행해도 문제를 풀지 못함

```
0 0.7842277884483337

1000 0.6931471824645996

2000 0.6931471824645996

3000 0.6931471824645996

4000 0.6931471824645996

5000 0.6931471824645996

6000 0.6931471824645996

7000 0.6931471824645996

8000 0.6931471824645996

9000 0.6931471824645996

10000 0.6931471824645996

PRED= [[0.0], [0.0], [0.0], [0.0]]

GOLD= [[0.0], [1.0], [1.0], [0.0]]
```



Deep ANN

Hidden layer 층을 1개에서 2개로 변경



Deeping은 선을 구부리는 효과!

오래 걸리지만 학습됨

```
0 0.6953558921813965

100 0.6930767893791199

200 0.6930528283119202

300 0.693021297454834

400 0.6929775476455688

500 0.6929132342338562

600 0.6928118467330933

700 0.692637026309967

800 0.6922969818115234

900 0.6915085315704346

1000 0.6891056299209595

PRED= [[1.0], [0.0], [1.0], [0.0]]

GOLD= [[0.0], [1.0], [1.0], [0.0]]
```



0 0.7725627422332764
300 0.693056046962738
600 0.6929765939712524
900 0.69272780418396
1200 0.6910351514816284
1500 0.5805514454841614
1800 0.085045225918293
2100 0.014176958240568638
2400 0.0076338378712534904
2700 0.0052098375745117664
3000 0.003949393518269062
PRED= [[0.0], [1.0], [1.0], [0.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]



Deeper ANN

Hidden layer 층을 1개에서 7개로 변경



10,000 epoch를 돌려도 학습이 안됨!

```
0 0.7086373567581177
100 0.6931471824645996
200 0.6931471824645996
300 0.6931471824645996
400 0.6931471824645996
500 0.6931471824645996
600 0.6931471824645996
700 0.6931471824645996
800 0.6931471824645996
900 0.6931471824645996
1000 0.6931472420692444
PRED= [[1.0], [0.0], [0.0], [1.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]
```



```
0 0.6933478713035583

1000 0.6931472420692444

2000 0.6931471824645996

4000 0.6931471824645996

5000 0.6931471824645996

6000 0.6931471824645996

7000 0.6931471824645996

8000 0.6931471824645996

9000 0.6931471824645996

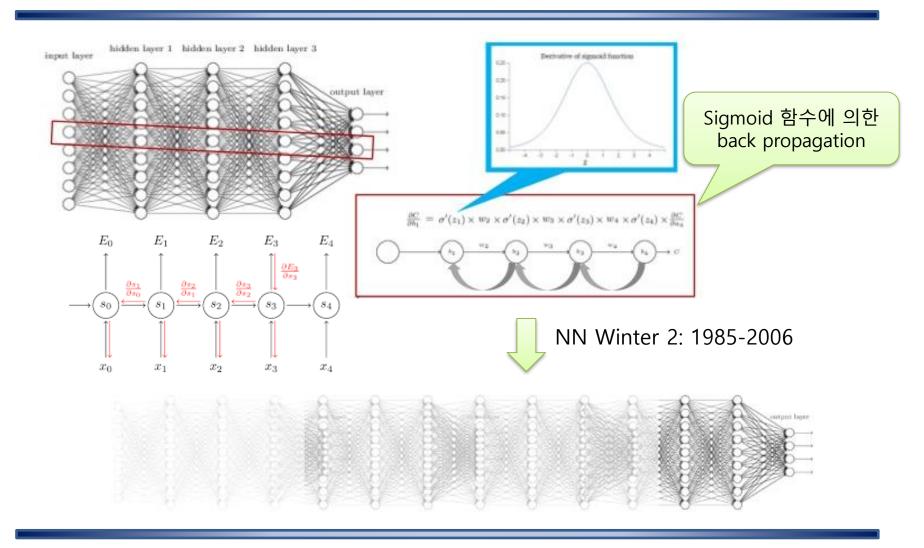
10000 0.6931471824645996

PRED= [[0.0], [1.0], [0.0], [0.0]]

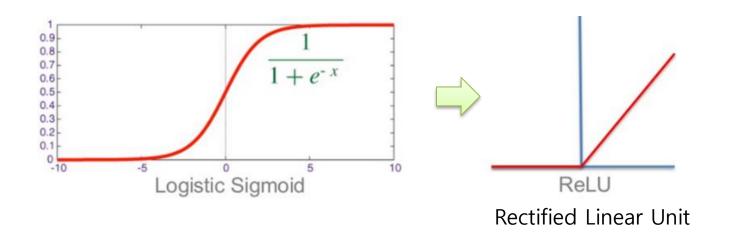
GOLD= [[0.0], [1.0], [1.0], [0.0]]
```

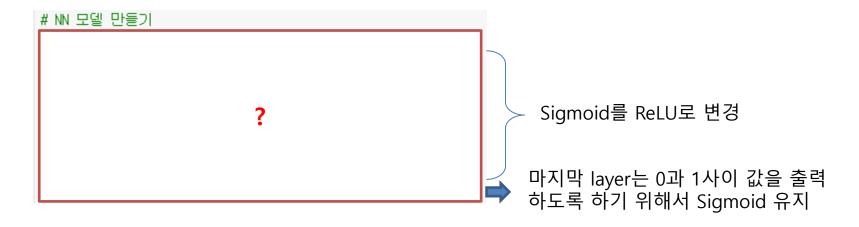


Vanishing Gradient



Sigmoid to ReLU







Sigmoid to ReLU

VS.

Vanishing gradient 문제가 사라짐

Sigmoid (10,000 epoch)

```
0 0.6933478713035583

1000 0.6931472420692444

2000 0.6931471824645996

4000 0.6931471824645996

5000 0.6931471824645996

5000 0.6931471824645996

6000 0.6931471824645996

8000 0.6931471824645996

8000 0.6931471824645996

10000 0.6931471824645996

PRED= [[0.0], [1.0], [0.0], [0.0]]

GOLD= [[0.0], [1.0], [1.0], [0.0]]
```

ReLU (3,000 epoch)

```
0 0.6946406960487366

300 0.6931304931640625

600 0.6931031942367554

900 0.6930624842643738

1200 0.6929516196250916

1500 0.6924918293952942

1800 0.6677674055099487

2100 0.0012112632393836975

2400 0.0003007405321113765

2700 0.00014935494982637465

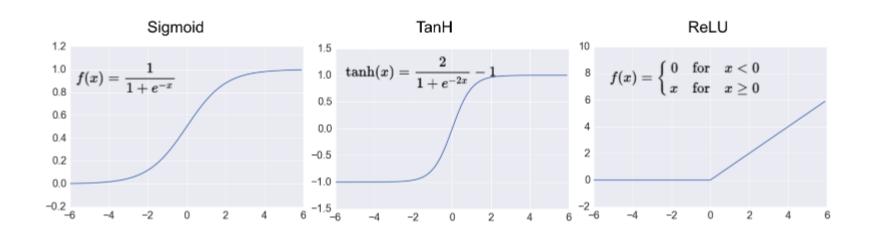
3000 9.424101881450042e-05

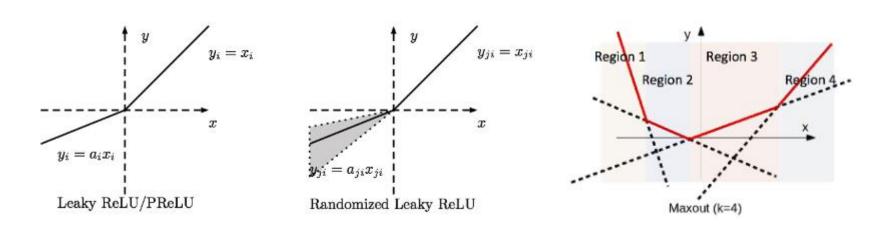
PRED= [[0.0], [1.0], [1.0], [0.0]]

GOLD= [[0.0], [1.0], [1.0], [0.0]]
```



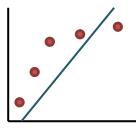
Activation Functions





Fitting

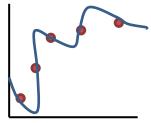
• 적합



Underfitting (high bias)



More training!



Overfitting (high variance)



More training data Reduce the number of features Regularization

Regularization

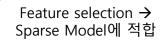
- Regularization (정규화, 일반화)
 - Cost function 값이 작아지는 방향으로 학습하는 과정에서 특정 가중치
 가 너무 커져서 일반화 성능이 떨어지는 것을 방지하기 위한 방법
 - L1 regularization

$$D(S,L) = -\frac{1}{N} \sum_{i} L_{i} log(S_{i}) + \lambda \sum_{i} |W| \cdot \circ$$

- L2 Regularization

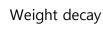
$$D(S,L) = -\frac{1}{N} \sum_{i} L_{i} log(S_{i}) + \lambda \sum_{i} W^{2} \cdot o$$

- Early Stopping
 - Dev set에서 성능이 더 이상 증가하지 않을 때 지정 횟수보다 학습을 일찍 끝마치는 것
- Dropout



$$a = [0.1, 0.5, 0.2] \rightarrow ||a|| = 0.8$$

 $b = [0.3, 0.5, 0.0] \rightarrow ||b|| = 0.8$



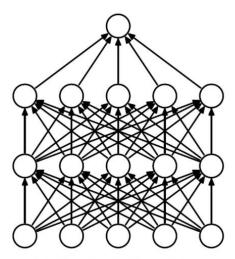
$$a = [0.1, 0.5, 0.2] \rightarrow ||a||_2 = 0.55$$

 $b = [0.3, 0.5, 0.0] \rightarrow ||b||_2 = 0.58$

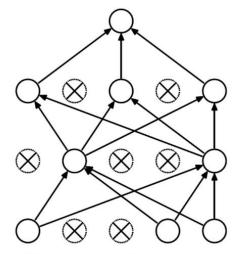


Dropout

- 드롭아웃
 - 학습 과정 중에 지정된 비율로 임의의 연결을 끊음으로써 일반
 화 성능을 개선하는 방법



(a) Standard Neural Net



(b) After applying dropout.

그림 출처: https://medium.com/@gopalkalpande/biological-inspiration-of-convolutional-neural-network-cnn-9419668898ac

Dropout by PyTorch

```
# NN 모델 만들기
model = nn.Sequential(
         nn.Linear(2, 10, bias=True), nn.ReLU(), nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU()
                                               nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU()
                                                nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU()
                                                nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU()
                                                nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU()
                                                nn.Dropout(0.1)
         nn.Linear(10, 10, bias=True), nn.ReLU(), nn.Dropout(0.1
         nn.Linear(10, 1, bias=True), nn.Sigmoid()).to(device)
# 이진분류 크로스엔트로피 비용 함수
loss func = torch.nn.BCELoss().to(device)
# 옵티마이저 함수 (역전파 알고리즘을 수행할 함수)
optimizer = torch.optim.SGD(model.parameters(), Ir=0.2)
# 학습 모드 셋팅
model.train()
```

```
# 평가 모드 셋팅 (학습 시에 적용했던 드랍 아웃 여부 등을 비적용)
model.eval()

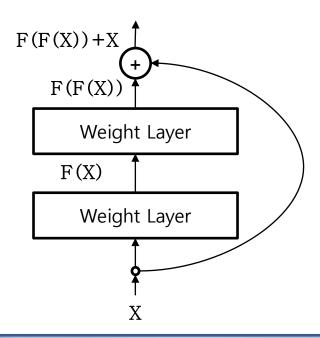
# 역전파를 적용하지 않도록 context manager 설정
with torch.no_grad():
    hypothesis = model(input_features)
```

```
DATA= [[0. 0. 0.1
 [0, 1, 1,]
 [1, 0, 1,]
 [1. 1. 0.]]
INPUT_FEATURES= [[0. 0.]
 [0.1.]
 [1. 0.]
 [1, 1, 1]
LABELS= [[0.]
 [1.]
 [1.]
 [0.1]
0.0.7056415677070618
300 0.6939449310302734
600 0.6798115968704224
900 0.6760240197181702
1200 0.7288740873336792
1500 0.5377387404441833
1800 0.4900955557823181
2100 0.00430224509909749
2400 0.2083825021982193
2700 0.6571221351623535
3000 0.0671871230006218
PRED= [[0.0], [1.0], [1.0], [0.0]]
GOLD= [[0.0], [1.0], [1.0], [0.0]]
Accuracy : 1,000000
```



Residual Connection

- 추가 연결
 - 가중치층을 우회하여 상위 층으로 직접 연결하는 것
 - 추상화 정도(낮은 수준 추상화와 높은 수준 추상화)를 적절히 섞 어주는 효과 → 앙상블 효과를 통해 성능 개선



```
import os
import numpy as np
from sklearn.metrics import accuracy_score
import torch
import torch.nn as nn
from torch.utils.data import (DataLoader, RandomSampler, TensorDataset)
```

Configure in main

Hypothesis 만들기

```
class XOR(nn.Module):
                                           XOR Class
 def __init__(self, config)
   super(XOR, self).__/nit__()
   # 입력층 노도 수
    self.inode = config["input_node"]
    # 은닉총 데이터 크기
   self.hnode = config["hidden_node"]
    # 출력층 노드 수: 분류해야 하는 레이블 수
   self.onode = config["output node"]
   # 활성화 함수로 Sigmoid 사용
   self.activation = nn.Sigmoid()
   # 신경망 설계
   self.linear1 = nn.Linear(self.inode, self.hnode, bias=True)
   self.linear2 = nn.Linear(self.hnode, self.onode, bias=True)
 def forward(self, input_features):
   output1 = self.linear1(input features)
   hypothesis1 = self.activation(output1)
   output2 = self.linear2(hypothesis1)
   hypothesis2 = self.activation(output2)
   return hypothesis2
```

데이터 읽기 함수

def load_dataset(file):
 data = np.loadtxt(file)

Training 함수

```
print("DATA=".data)
# 모델 학습 함수
                                                                                    input_features = data[:,0:-1]
def train(config):
                                                                                    print("INPUT_FEATURES=",input_features)
                                                                                    labels = np.reshape(data[:,-1],(4,1))
 #모델 생성
                                                                                    print("LABELS=".labels)
 model = XOR(config).cuda()
                                                                                    input_features = torch.tensor(input_features, dtype=torch.float)
 # 데이터 읽기
                                                                                    labels = torch.tensor(labels, dtype=torch.float)
 (input features, labels) = load dataset(config["input data"])
                                                                                    return (input_features, labels)
 # TensorDataset/DataLoader를 통해 배치(batch) 단위로 데이터를 나누고 서플(shuffle)
 train_features = TensorDataset(input_features, labels)
 train_dataloader = DataLoader(train_features, shuffle=True, batch_size=config["batch_size"])
 # 이진분류 크로스엔트로피 비용 함수
 loss_func = nn.BCELoss()
 # 옵티마이저 함수 (역전파 알고리즘을 수행할 함수)
 optimizer = torch.optim.SGD(model.parameters(), Ir=config["learn_rate"])
```

```
for epoch in range(config["epoch"]+1):
 # 학습 모드 셋팅
 model.train()
 # epoch 마다 평균 비용을 저장하기 위한 리스트
 costs = []
 for (step, batch) in enumerate(train_dataloader):
   # batch = (input_features[step], labels[step])*batch_size
   # .cuda()를 통해 메모리에 업로드
   batch = tuple(t.cuda() for t in batch)
   # 각 feature 저장
   input features. labels = batch
   # 역전파 변화도 초기화
   # .backward() 호출 시, 변화도 버퍼에 데이터가 계속 누적한 것을 초기화
   optimizer.zero_grad()
   # H(X) 계산: forward 연산
   hypothesis = model(input features)
   # 비용 계산
   cost = loss_func(hypothesis, labels)
   # 역전파 수행
                                  # 100 에폭마다 평균 loss 출력하고 모델을 저장
   cost.backward()
   optimizer.step()
                                  if epoch%100 == 0:
                                    print("Average Loss= {0:f}".format(np.mean(costs)))
                                    torch.save(model.state dict(), os.path.join(config["output dir"], "epoch {0:d}.pt".format(epoch)))
   # 현재 batch의 스텝 별 Toss 저장
   costs.append(cost.data.item())
                                    do_test(model, train_dataloader)
```



Test 함수

```
# 모델 평가 함수

def test(config):

model = XOR(config).cuda()

# 저장된 모델 가중치 로드

model.load_state_dict(torch.load(os.path.join(config["output_dir"], config["model_name"])))

# 데이터 load

(features, labels) = load_dataset(config["input_data"])

test_features = TensorDataset(features, labels)

test_dataloader = DataLoader(test_features, shuffle=True, batch_size=config["batch_size"])

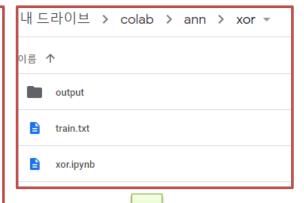
do_test(model, test_dataloader)
```

```
# 모델 평가 결과 계산을 위해 텐서를 리스트로 변환하는 함수
def tensor2list(input tensor):
   return input_tensor.cpu().detach().numpy().tolist()
# 평가 수행 함수
def do_test(model, test_dataloader):
 # 평가 모드 셋팅
 model.eval()
 # Batch 별로 예측값과 정답을 저장할 리스트 초기화
 predicts, golds = [], []
 with torch.no_grad():
   for step, batch in enumerate(test dataloader):
     # .cuda()를 통해 메모리에 업로드
     batch = tuple(t.cuda() for t in batch)
     input_features, labels = batch
     hypothesis = model(input features)
     logits = (hypothesis > 0.5).float()
     x = tensor2list(logits)
     y = tensor2list(labels)
     # 예측값과 정답을 리스트에 추가
     predicts.extend(x)
     golds.extend(v)
   print("PRED=",predicts)
   print("GOLD=",golds)
   print("Accuracy= {0:f}\m".format(accuracy_score(golds, predicts)))
```

Training in Main

```
if(__name__=="__main__"):
   root_dir = "/gdrive/My Drive/colab/ann/xor"
   output_dir = os.path.join(root_dir, "output")
   if not os.path.exists(output_dir):
        os.makedirs(output_dir)
   input data = "{0:s}/{1:s}".format(root dir."train.txt")
   config = {|mode": "train"
              "model_name":"epoch_{0:d}.pt".format(1000),
              "output_dir":output_dir,
              "input_data":input_data,
              "input node":2.
              "hidden_node":10.
              "output_node":1.
              "learn_rate":1,
              "batch_size":4,
              "epoch":1000,
    if(config["mode"] == "train"):
        train(config)
   else:
        test(config)
```

```
DATA= [[0, 0, 0.]
 [0. 1. 1.]
 [1. 0. 1.]
 [1, 1, 0,]]
INPUT_FEATURES= [[0, 0,]
 [0, 1, 1]
 [1. 0.]
 [1, 1,]]
LABELS= [[0.1
 [1.]
 [1.]
 [0.]]
Average Loss= 0.693318
PRED= [[0.0], [0.0], [1.0], [1.0]]
GOLD= [[1.0], [0.0], [0.0], [1.0]]
Accuracy= 0.500000
Average Loss= 0.690562
PRED= [[1.0], [1.0], [0.0], [0.0]]
GOLD= [[1.0], [0.0], [1.0], [0.0]]
Accuracy= 0.500000
Average Loss= 0.667773
PRED= [[0.0], [1.0], [0.0], [1.0]]
GOLD= [[1.0], [1.0], [0.0], [0.0]]
Accuracy= 0.500000
Average Loss= 0.433278
PRED= [[1.0], [0.0], [0.0], [1.0]]
GOLD= [[1.0], [0.0], [0.0], [1.0]]
Accuracy= 1.000000
Average Loss= 0.133441
PRED= [[0.0], [1.0], [0.0], [1.0]]
GOLD= [[0.0], [1.0], [0.0], [1.0]]
Accuracy= 1.000000
```







Test in Main

```
if(__name__=="__main__"):
    root_dir = "/gdrive/My Drive/colab/ann/xor"
    output_dir = os.path.join(root_dir, "output")
    if not os.path.exists(output_dir):
        os.makedirs(output dir)
    input_data = "{0:s}/{1:s}".format(root_dir,"train.txt")
    config = ["mode": "test",
              "model_name":"epoch_{0:d}.pt".format(1000)
              "output_dir":output_dir,
              "input_data":input_data,
              "input_node":2,
              "hidden_node":10.
              "output node":1.
              "learn_rate":1.
              "batch_size":4.
              "epoch":1000.
    if(config["mode"] == "train"):
        train(config)
    else:
        test(config)
```

1,000 epoch 모델 결과를 읽어 들여 테스트 수행

```
DATA= [[0. 0. 0.]
  [0. 1. 1.]
  [1. 0. 1.]
  [1. 1. 0.]]
INPUT_FEATURES= [[0. 0.]
  [0. 1.]
  [1. 0.]
  [1. 1.]]
LABELS= [[0.]
  [1.]
  [1.]
  [0.]]
PRED= [[0.0], [1.0], [1.0], [0.0]]
Accuracy= 1.000000
```







Simple ML Programming

Practical Exercise



• SMSSpamCollection 데이터를 입력으로 하는 SVM 기반 스팸 메일 필터링 프로그램을 작성하시오.

/KUNLP/KTAI-

Practice

- SMSSpamCollection 데이터 형식
 - ham/spam ₩t 문장

```
ham Go until jurong point, crazy.. Available only in bugis
ham Ok lar... Joking wif u oni...
        Free entry in 2 a wkly comp to win FA Cup final tkt
spam
ham U dun say so early hor... U c already then say...
ham Nah I don't think he goes to usf, he lives around here
        FreeMsg Hev there darling it's been 3 week's now an
spam
ham Even my brother is not like to speak with me. They trea
ham As per your request 'Melle Melle (Oru Minnaminunginte N
       WINNER!! As a valued network customer you have been
spam
        Had your mobile 11 months or more? U R entitled to
spam
ham I'm gonna be home soon and i don't want to talk about t
        SIX chances to win CASH! From 100 to 20,000 pounds
spam
```

구글 colab 연결

```
from google.colab import drive
drive.mount("/gdrive", force_remount=True)
```

데이터 읽기 (처음부터 100개)

```
import numpy as np

file_path = "/gdrive/My Drive/colab/svm/SMSSpamCollection"

# 파일 읽기
x_data, y_data = [], []
with open(file_path,'r',encoding='utf8') as inFile:
    lines = inFile.readlines()

lines = lines[:100]

for line in lines:
    line = line.strip().split('\text{\frac{\psi}{\psi}}')
    sentence, label = line[1], line[0]
    x_data.append(sentence)
    y_data.append(label)

print("x_data의 개수: " + str(len(x_data)))
print("y_data의 개수: " + str(len(y_data)))
```

x_data의 개수 : 100 y_data의 개수 : 100



데이터 변환 (문자열 → 숫자)

```
from keras, preprocessing, text import Tokenizer
tokenizer = Tokenizer()
# spam, ham 라벨을 대용하는 index로 치환하기위한 딕셔너리
label2index_dict = {'spam':0, 'ham':1}
# indexing 한 데이터를 넣을 리스트 선언
indexing_x_data, indexing_v_data = [], []
for label in v data:
  indexing_v_data.append(label2index_dict[label])
# x data를 사용하여 딕셔너리 생성
tokenizer.fit_on_texts(x_data)
# x data에 있는 각 문장의 단어들을 대응하는 index로 치환하고 그 결과값을 indexing x data에 저장
indexing x data = tokenizer.texts to sequences(x data)
print("x_data indexing 하기 전 : " + str(x_data[0]))
print("x_data indexing 하기 후 : " + str(indexing_x_data[0]))
print("y_data indexing 하기 전 : " + str(y_data[0]))
print("y_data_indexing 하기 후 : " + str(indexing_y_data[0]))
 x_data indexing 하기 전 : Go until jurong point, crazy.. Available only in bugis n great world la e buffet... Cine there got amore wat...
 x data indexing 하기 후 : [38, 93, 239, 240, 241, 242, 53, 11, 243, 72, 94, 244, 245, 126, 246, 247, 73, 74, 248, 127]
 y_data indexing 하기 전 : ham
 y_data indexing 하기 후 : 1
```



SVM 학습

```
from sklearn.svm import SVC
# 문장의 길이를 max_length으로 맞춰 변환
max length = 60
for index in range(len(indexing_x_data)):
  length = len(indexing x data[index])
  if(length > max_length):
    indexing_x_data[index] = indexing_x_data[index][:max_length]
  elif(length < max length):
                                                                                            Soft Margin 슬랙의 C 값!
    indexing x data[index] = indexing x data[index] + [0]*(max_length-length)
# 전체 데이터를 9:1의 비율로 나누어 학습 및 평가 데이터로 사용
                                                              minimize: Q_1(w, b, \xi_i) = \frac{1}{2} ||\mathbf{w}||^2 + C \sum_i \xi_i
number_of_train = int(len(indexing_x_data)*0.9)
                                                              subject to: y_i(\mathbf{w} \cdot \mathbf{x}_i - b) \ge 1 - \xi_i, \forall (\mathbf{x}_i, y_i) \in D
train_x = indexing_x_data[:number_of_train]
                                                                                    \xi_i > 0
train_y = indexing_y_data[:number_of_train]
test_x = indexing_x_data[number_of_train:]
                                                    train_x의 개수 : 90
test_y = indexing_y_data[number_of_train:]
                                                    train_y의 개수 : 90
                                                    test_x의 개수 : 10
print("train_x의 개수 : " + str(len(train_x)))
                                                    test_v의 개수 : 10
print("train_y의 개수: " + str(len(train_y)))
                                                    SVC(C=1000000000.0, break_ties=False, cache_size=200, class_weight=None,
print("test_x의 개수: " + str(len(test_x)))
                                                         coef0=0.0, decision_function_shape='ovr', degree=3, gamma='scale',
print("test_y의 개수: " + str(len(test_y)))
                                                         kernel='linear', max_iter=-1, probability=False, random_state=None,
                                                         shrinking=True, tol=0.001, verbose=False)
svm = SVC(kernel='linear', C=1e10)
svm.fit(train_x, train_y)
```



SVM 평가

```
predict = svm.predict(test_x)
correct_count = 0
for index in range(len(predict)):
 if(test_y[index] == predict[index]):
   correct_count += 1
accuracy = 100.0*correct_count/len(test_v)
print("Accuracy: " + str(accuracy))
index2label = {0:"spam", 1:"ham"}
test x word = tokenizer.sequences to texts(test x)
for index in range(len(test x word)):
 print()
 print("문장 : ", test_x_word[index])
 print("정답: ", index2label[test_y[index]])
 print("모델 출력 : ". index2[abel[predict[index]]])
```

```
Accuracy: 80.0
문장: yeah do don 't stand to close tho you 'll catch son
모델 출력 : spam
문장 : sorry to be a pain is it ok if we meet another nigh
정답: ham
모델 충력 : spam
문장 : smile in pleasure smile in pain smile when trouble
정답: ham
모델 출력 : ham
문장 : please call our customer service representative on
정답: spam
모델 출력 : spam
문장: havent planning to buy later i check already lido
정답: ham
모델 충력 : ham
문장 : your free ringtone is waiting to be collected simp
정답: spam
모델 출력 : spam
```

과제

- 영어 불용어 리스트를 참고하여 입력 문장에서 불용어를 제거한 SVM 기반 스팸 메일 필터를 구현하시오. (10점)
 - 불용어 리스트를 얻는 방법

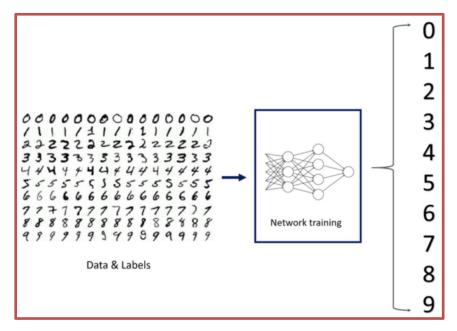
```
import nltk

print('영어 불용어 갯수:',len(nltk.corpus.stopwords.words('english')))
print(nltk.corpus.stopwords.words('english')[:10])

영어 불용어 갯수: 179
['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "you're"]
```

예제 코드 다운로드: https://github.com /KUNLP/KTAI-Practice

- XOR 문제에 사용한 "ANN Class in PyTorch" 프로그램을 수정하여 손 글씨 숫자를 판독하는 프로그램을 작성하시 오.
 - 입력 데이터셋
 - MNIST dataset
 - 0~9 손 글씨 이미지에 대한 픽셀 값 데이터
 - 문제
 - 이미지의 픽셀 값을 입력으로 하여 해당 이미지가 0~9
 중에 어떤 숫자인지 분류



```
class MNIST(nn.Module):
                                                                import os
                                             MNIST Class
                                                               import numby as no
                                                               from sklearn.metrics import accuracy_score
  def init (self. config):
                                                                import torch
                                                               import torch.nn as nn
                                                               from torch.utils.data import (DataLoader, RandomSampler, TensorDataset)
    # 입력층 노드 수
                                                               from keras, datasets import mnist
    self.inode = config["input node"]
    # 은닉층 데이터 크기
                                                                # 데이터 읽기 함수
                                                                                                          데이터 읽기
    self.hnode = config["hidden_node"]
                                                                def load_dataset():
    # 출력층 노드 수: 분류해야 하는 레이블 수
    self.onode = config["output node"]
    # 활성화 함수로 Sigmoid 사용
                                                                                 ? (keras.datasets)
    self.activation = nn.Sigmoid()
    # 신경망 설계
    self.linear1 = nn.Linear(self.inode, self.hnode, bias=True)
    self.linear2 = nn.Linear(self.hnode, self.onode, bias=True)
                                                                  train_X = train_X.reshape(-1, 28*28)
                                                                  print(train_X.shape)
  def forward(self, input features):
                                                                  test_X = test_X.reshape(-1, 28*28)
    output1 = self.linear1(input features)
                                                                  train_X = torch.tensor(train_X, dtype=torch.float)
    hypothesis1 = self.activation(output1)
                                                                  train_y = torch.tensor(train_y, dtype=torch.long)
                                                                  test_X = torch.tensor(test_X, dtype=torch.float)
    output2 = self.linear2(hypothesis1)
                                                                  test_y = torch.tensor(test_y, dtype=torch.long)
    hypothesis2 = self.activation(output2)
                                                                  return (train_X, train_y), (test_X, test_y)
    return hypothesis2
```



```
#모델 학습 함수
                                                                        Training 함수
def train(config):
 # TensorDataset/DataLoader를 통해 배치(batch) 단위로 데이터를 나누고 셔플(shuffle)
 train_features = TensorDataset(input_features, labels)
 train_dataloader = DataLoader(train_features, shuffle=True, batch_size=config["batch_size"])
  # 현재 batch의 스텝 별 loss 저장
  costs.append(cost.data.item())
# 에폭마다 평균 비용s 출력하고 모델을 저장
print("Average Loss= {0:f}".format(np.mean(costs)))
torch.save(model.state_dict(), os.path.join(config["output_dir"], "epoch_{0:d}.pt".format(epoch)))
```



do_test(model, train_dataloader)

Main

```
if(__name__=="__main__"):
   root_dir = "/gdrive/My Drive/colab/ann/mnist"
   output_dir = os.path.join(root_dir, "output")
   if not os.path.exists(output_dir):
        os.makedirs(output_dir)
   config = {"mode": "train".
              "model_name":"epoch_{0:d}.pt".format(10).
              "output_dir":output_dir,
              "input node": 784.
              "hidden node":512.
              "output_node":10,
              "learn rate": 0.001.
              "batch size":32.
              "epoch":10.
   if(config["mode"] == "train"):
        train(config)
   else:
       test(config)
```

과제

빈칸 채우기: 10점

```
Downloading data from https://storage.googleapis.com/tensorflow
(60000, 28, 28)
(60000.)
(10000, 28, 28)
(100000.)
(60000, 784)
Average Loss= 1.620250
PRED= [3, 2, 1, 0, 4, 1, 4, 1, 9, 6, 1, 4, 5, 7, 5, 4, 7, 8, 4,
GOLD= [3, 2, 1, 0, 4, 1, 4, 1, 9, 6, 1, 4, 5, 7, 5, 4, 7, 2, 4,
Accuracy= 0.915850
Average Loss= 1.563620
PRED= [0, 8, 7, 9, 1, 7, 7, 6, 3, 6, 9, 3, 1, 6, 8, 7, 2, 1, 9,
GOLD= [0, 8, 7, 3, 1, 7, 7, 6, 3, 6, 9, 3, 1, 6, 8, 7, 2, 1, 9,
Accuracy= 0.918350
Average Loss= 1.551876
PRED= [9, 8, 8, 4, 3, 0, 5, 9, 0, 2, 1, 8, 7, 1, 1, 1, 8, 2, 9,
GOLD= [9, 8, 8, 4, 3, 6, 5, 9, 0, 2, 1, 8, 7, 1, 1, 1, 5, 2, 9,
Accuracy= 0.922050
```



질의응답



Homepage: http://nlp.konkuk.ac.kr E-mail: nlpdrkim@konkuk.ac.kr